
Comparación de aprendizaje por refuerzo (PPO) vs aprendizaje supervisado (LSTM) para trading en portafolios multi-activo

Sebastián Terrazas^{* 1} Matías Orbeta^{* 1}

Abstract

Se comparan métodos de aprendizaje por refuerzo (PPO) (Schulman et al., 2017) y aprendizaje supervisado (redes LSTM) (Hochreiter & Schmidhuber, 1997) en la gestión de un portafolio multi-activo con SPY, BTC y TLT. El entorno de trading simulado emplea datos históricos diarios, ventanas temporales de entrenamiento, validación y prueba, así como costos de transacción realistas (0.2% por operación). Se evalúa el desempeño con métricas financieras estándar como retorno acumulado, índice de Sharpe y drawdown máximo. En el conjunto de prueba (2019-2024), PPO-T 30k alcanza un retorno anualizado de 36.1% (Sharpe 0.63) vs 22.4% (Sharpe 0.91) del LSTM. PPO 100k obtiene 15.7% anualizado con Sharpe 1.08, superando al LSTM en eficiencia riesgo-retorno. Estos resultados sugieren un trade-off entre agresividad y estabilidad en las variantes PPO evaluadas.

1. Introducción

Los mercados financieros actuales permiten el uso de algoritmos de trading automatizado basados en aprendizaje automático. En particular, la gestión de portafolios multi-activo (por ejemplo, combinando acciones, criptomonedas y bonos) enfrenta desafíos debido a la distinta volatilidad de cada activo y la necesidad de balancear riesgo y retorno. En este contexto, se investigan enfoques basados en aprendizaje por refuerzo y métodos supervisados para generar estrategias de trading. Los métodos tradicionales de trading automático incluyen análisis técnico y modelos estadísticos, pero en los últimos años se han explorado técnicas de *deep learning*. Por ejemplo, las redes neuronales LSTM se em-

plean para predecir series temporales de precios financieros, mientras que los algoritmos de aprendizaje por refuerzo aprenden directamente políticas de inversión basadas en recompensas definidas por rendimiento financiero. Estos dos paradigmas representan enfoques distintos: LSTM se basa en aprendizaje supervisado para extraer señales del mercado, mientras que PPO es un método de actor-crítico que ajusta la política para maximizar la recompensa acumulada. Este estudio implementa y compara ambos enfoques en un portafolio compuesto por SPY (ETF del S&P 500), BTC (Bitcoin) y TLT (ETF de bonos del Tesoro a largo plazo). Se incluyen costos de transacción realistas y se evalúa el desempeño utilizando conjuntos de datos separados para entrenamiento, validación y prueba. El objetivo es determinar cuál de los métodos ofrece mejor desempeño en términos de retorno ajustado al riesgo.

- Implementación de un agente PPO de aprendizaje por refuerzo para trading multi-activo.
- Diseño de un modelo supervisado basado en LSTM para predicción de señales de inversión.
- Comparación exhaustiva de ambos enfoques en presencia de costos de transacción realistas.
- Evaluación mediante métricas financieras clave (retorno acumulado, índice de Sharpe, drawdown máximo).

2. Preliminares

En esta sección se presenta brevemente el trasfondo teórico relevante. Se modela la tarea de trading como un proceso de decisión de Markov (MDP) siguiendo la formulación estándar de RL (Sutton & Barto, 2018). PPO (Proximal Policy Optimization) es un algoritmo actor-crítico propuesto por (Schulman et al., 2017) que ha demostrado estabilidad y eficiencia en entornos complejos, gracias a un mecanismo de recorte en la función objetivo que previene cambios drásticos en la política. Las redes LSTM (Long Short-Term Memory) fueron introducidas por Hochreiter y Schmidhuber (1997) para manejar dependencias de largo plazo en series temporales. En el contexto financiero, las LSTM se emplean ampliamente para filtrar ruido en los datos y extraer

^{*}Equal contribution ¹Department of Computer Science, Pontificia Universidad Católica de Chile, Santiago, Chile. Correspondence to: Matías Orbeta <morbeta@uc.cl>, Sebastián Terrazas <sebaterrazas@uc.cl>.

patrones temporales. Una LSTM procesa secuencias de precios o indicadores técnicos y aprende a clasificar acciones de trading óptimas, actuando como modelo supervisado que minimiza el error de clasificación. Se consideran además métricas financieras estándar para evaluar desempeño:

- **Retorno acumulado:** Ganancia total del portafolio en el periodo de prueba.
- **Índice de Sharpe:** Ratio anualizado de rentabilidad promedio sobre desviación estándar de la rentabilidad, asumiendo tasa libre de riesgo nula.
- **Drawdown máximo:** Caída máxima porcentual desde un máximo histórico en la curva de valor del portafolio.

3. Trabajos Relacionados

Numerosos estudios han explorado la aplicación de RL y de modelos secuenciales en trading financiero. Se han empleado variantes de aprendizaje por refuerzo (p.ej. DQN, A2C, DDPG) en activos individuales con el objetivo de maximizar el retorno. Algunos trabajos combinan LSTM y PPO; por ejemplo, Zou et al. (2023) proponen el modelo CLSTM-PPO, que extrae características con LSTM antes de entrenar un agente PPO, reportando mejoras sustanciales en el retorno acumulado. Sin embargo, la literatura que considera simultáneamente acciones, criptomonedas y bonos en un portafolio es limitada, lo cual motiva la presente comparación.

4. Metodología

Los experimentos se basan en un entorno de trading diario. El estado s_t incluye información histórica reciente de cada activo (por ejemplo, precios ajustados de los últimos T días). El agente selecciona en cada paso un vector de asignaciones de portafolio w_t (pesos para SPY, BTC, TLT) con $\sum_i w_{i,t} = 1$ y $w_{i,t} \geq 0$. El retorno del portafolio en el paso t es $R_t = \sum_i w_{i,t} r_{i,t}$ (donde $r_{i,t}$ es el retorno del activo i), y la recompensa del agente se define como la diferencia entre el retorno del portafolio y los costos de transacción incurridos al reequilibrarlo.

El agente PPO se implementa con una red neuronal actor-crítico. La red toma s_t como entrada y produce la política $\pi(a|s_t)$ y la función de valor $V(s_t)$. La política parametrizada genera acciones continuas (pesos del portafolio) mediante una capa *softmax*. Se emplean técnicas estándar de PPO: factor de descuento $\gamma = 0.99$, clipping $\epsilon = 0.2$ y actualizaciones por lotes. La arquitectura de la red consiste en capas densas (por ejemplo, 128 y 64 unidades con activación ReLU) seguidas por capas de salida para la política y la función de valor.

Modelo LSTM multiactivo (nuestra implementación).

Inspirados en (Fischer & Krauss, 2018), implementamos una red LSTM multiactivo que procesa simultáneamente 39 features por día: 30 indicadores técnicos (10 por activo: retornos, momentum, volatilidad, RSI, ratios de medias móviles), 5 features cross-asset (correlaciones entre activos, volatilidad de mercado) y 4 variables de portafolio (balance normalizado, valor de posiciones). Con una ventana temporal de $T = 20$ días, la entrada tiene dimensión 20×39 . La LSTM (25 unidades, 1 capa, dropout 0.1) alimenta capas densas (25-25-12 neuronas) que producen logits para 5 clases por activo: *Strong Sell*, *Sell*, *Hold*, *Buy*, *Strong Buy*. Se entrena minimizando CrossEntropy sumando pérdidas por activo:

$$\mathcal{L} = \sum_{i \in \{\text{BTC}, \text{SP500}, \text{Bonds}\}} \text{CE}(z^{(i)}, y^{(i)})$$

Los targets se generan con look-ahead de 3 días: se computa el retorno futuro $r_{t \rightarrow t+3}$, se obtienen percentiles (25-40-60-75) y se etiqueta la clase correspondiente para balancear clases. Durante inferencia se ejecuta $\arg \max$ sobre las 5 clases con restricciones: máximo 10% del portafolio para compras y 20% de posiciones para ventas; no se permite short selling.

Variantes de modelos PPO implementados. Se evalúan tres configuraciones distintas de PPO para analizar el impacto de la arquitectura neural y el tiempo de entrenamiento:

PPO-T 30k (Transformer): Emplea un extractor de características basado en arquitectura Transformer como pre-procesador antes de las capas actor-crítico. El Transformer tiene 3 capas encoder con 4 cabezas de atención, dimensión de modelo $d = 128$, capa feed-forward de 4×128 unidades y dropout 0.1. La entrada se proyecta linealmente a d dimensiones, se añade codificación posicional y se procesa mediante self-attention. La salida alimenta redes densas separadas para política (actor) y función de valor (crítico) con arquitectura [64, 64]. Se entrena durante 30,000 timesteps con los hiperparámetros estándar de PPO.

PPO 30k (estándar): Utiliza redes neuronales densas tradicionales como extractor de características. El espacio de acciones consiste en 5 acciones discretas por activo: {Strong Sell, Moderate Sell, Hold, Moderate Buy, Strong Buy}, mapeadas a señales continuas $\{-1.0, -0.5, 0.0, 0.5, 1.0\}$. Las compras se limitan al 10% del valor del portafolio por transacción, mientras que las ventas pueden alcanzar el 20% de las posiciones actuales. La función de recompensa combina retornos tipo Sharpe (media/desviación estándar de retornos recientes) más un bonus de diversificación que favorece asignaciones balanceadas cercanas a [35% BTC, 40% SP500, 25% Bonds]. Se entrena durante 30,000 timesteps.

PPO 100k (estándar extendido): Idéntico al PPO 30k en arquitectura y función de recompensa, pero entrenado du-

rante 100,000 timesteps para evaluar el efecto de mayor tiempo de entrenamiento en la estabilidad y performance. Esta configuración permite analizar si el entrenamiento extendido produce políticas más conservadoras y estables.

Los datos históricos se dividen temporalmente en: entrenamiento (2010-2016), validación (2017-2018) y prueba (2019-2024), manteniendo el orden temporal. Se aplica un costo de transacción fijo de 0.2% por operación para ambos métodos. Los hiperparámetros del modelo LSTM (RMSProp lr=1e-3, batch size=512, early stopping patience=10, gradient clipping=0.5) se seleccionan usando el conjunto de validación siguiendo (Fischer & Krauss, 2018). En resumen, la configuración incluye:

- **Recompensa:** Retorno del portafolio menos costos de transacción.
- **Acciones PPO:** 5 acciones discretas por activo mapeadas a señales continuas $\{-1.0, -0.5, 0.0, 0.5, 1.0\}$.
- **Variantes PPO:** PPO-T 30k (Transformer + 30k timesteps), PPO 30k (estándar), PPO 100k (estándar extendido).
- **Hiperparámetros PPO:** $\gamma = 0.99$, $\epsilon = 0.2$, learning rate 3×10^{-4} , batch size 64, n_epochs 10.
- **Modelo LSTM:** Red LSTM multiactivo (25 unidades, 1 capa, dropout 0.1), entrenada con CrossEntropy para 5 clases por activo.
- **Señal de trading LSTM:** $\arg \max$ sobre 5 clases (Strong Sell/Sell/Hold/Buy/Strong Buy); restricciones: max 10% compras, 20% ventas.
- **División temporal:** 2010-2016 entrenamiento, 2017-2018 validación, 2019-2024 prueba (cronológico).

5. Experimentos

Se emplean datos diarios de precios ajustados de SPY, BTC y TLT desde enero de 2010 hasta diciembre de 2024. Los datos se dividen temporalmente en: entrenamiento (2010-2016), validación (2017-2018) y prueba (2019-2024) para mantener consistencia temporal. Se considera un costo de transacción del 0.2% por operación para ambas estrategias. Todos los resultados reportados corresponden a métricas promedio sobre varias corridas con diferente inicialización aleatoria.

En la figura de retorno acumulado, la estrategia Bitcoin Only domina con un retorno total de 2365.8%, estableciendo el benchmark más alto pero con volatilidad de 65.8%. El modelo PPO-T 30k alcanza 518.4% total (36.1% anual) con oscilaciones bruscas y drawdowns que superan el 76%. Por su parte, PPO 100k presenta retornos más moderados

Table 1. Resultados de rendimiento en el conjunto de prueba (2019-2024)

Estrategia	Retorno Total (%)	Retorno Anual (%)	Sharpe	Max Draw
Bitcoin Only	2365.81	72.02	1.09	-76
PPO 100k	136.81	15.71	1.08	-22
Aggressive	799.11	45.02	1.02	-64
Equal Weight	828.12	45.80	1.00	-68
Conservative	284.02	25.57	0.95	-54
LSTM	227.33	22.39	0.91	-41
S&P 500 Only	139.64	15.94	0.79	-33
PPO 30k	130.49	15.18	0.76	-33
PPO Bitcoin	390.24	30.87	0.64	-70
PPO-T 30k	518.39	36.12	0.63	-76
Free PPO 150k	507.36	35.70	0.61	-76

(136.8% total, 15.7% anual) pero con curvas mucho más suaves y menor volatilidad (14.6%). La LSTM alcanza 227.3% total (22.4% anual) con drawdown más controlado (-41.4%), pero su Sharpe ratio (0.91) indica menor eficiencia que PPO 100k (1.08).

Comparando PPO (100k) y PPO (30k), se observa que reducir los timesteps aumenta la agresividad —mayor exposición a BTC en test— pero también el riesgo y la inestabilidad de la curva. El modelo entrenado por más tiempo produce trayectorias más suaves, adaptándose peor a peaks repentinos pero ofreciendo mayor consistencia. La LSTM, en cambio, genera señales demasiado conservadoras: carece de apetito de riesgo tras los primeros 30 días y apenas rebasa la rentabilidad del S & P 500, lo cual limita su aplicabilidad en entornos de alta volatilidad.

Durante la fase de máxima incertidumbre, PPO-T 30k rebota con fuerza y recupera niveles históricos muy por encima del índice, aunque sufre caídas pronunciadas. PPO 100k replica mejor la trayectoria del S & P 500, capturando momentum alcista y amortiguando las caídas. PPO 30k queda entre ambos extremos, con mayor upside que PPO 100k pero mayor drawdown. La LSTM, en contraste, no logra aprovechar los movimientos extremos y mantiene una asignación excesivamente estable. Esto demuestra que, en mercados de alta volatilidad, un entrenamiento más corto puede explotar mejor los movimientos, pero a costa de una gestión de riesgo más acentuada.

En la sección de “Test Set Performance” todos los modelos comienzan igualados en cero. Durante la fase de máxima incertidumbre de 2020–2022, PPO-T 30k rebota con fuerza y recupera niveles históricos muy superiores al S&P, mientras que PPO 100k muestra una curva más parecida a la del índice, capturando momentum alcista pero limitando las caídas. El PPO 30k se sitúa entre ambos, con mayor subida que PPO 100k, pero también con drawdowns más pronunciados. Esta comparación evidencia que, en entornos de alta volatilidad, los modelos entrenados con menos pasos




Figure 1. (a) Rendimiento de Portafolio Acumulado. (b) Rendimiento Test Completo.

pueden explotar mejor los movimientos, a costa de gestionar peor el riesgo.

(0.63). El LSTM, con 22.4% de retorno y 24.7% de volatilidad, obtiene Sharpe 0.91, posicionándose competitivamente pero sin superar a PPO 100k en eficiencia riesgo-retorno.




Figure 2. Perfil Riesgo–Retorno

En el scatter de volatilidad vs retorno anual, Bitcoin Only domina con 72.0% de retorno anual y Sharpe 1.09, aunque con alta volatilidad (65.8%). Entre los modelos ML, PPO 100k logra el mejor trade-off riesgo-retorno con 15.7% anual y Sharpe 1.08, superando al S&P 500 Only (15.9% anual, Sharpe 0.79). PPO-T 30k exhibe mayor rentabilidad (36.1% anual) pero con volatilidad del 57.4% y Sharpe inferior




Figure 3. Métricas de Rendimiento

Al observar las barras de métricas, se confirma el análisis previo: Bitcoin Only lidera en rentabilidad (72.0% anual) y Sharpe (1.09), pero su max drawdown alcanza -76.6%. Entre los modelos ML, PPO-T 30k obtiene 36.1% anual pero con drawdown severo (-76.2%) y Sharpe bajo (0.63).

PPO 100k presenta el mejor balance con Sharpe 1.08 y drawdown más contenido (-22.3%), aunque con rentabilidad menor (15.7%). El LSTM obtiene Sharpe 0.91 y drawdown intermedio (-41.4%), superando a PPO-T 30k en eficiencia riesgo-retorno pero sin alcanzar a PPO 100k.




Figure 4. Asignación de Portafolio

La asignación promedio en el test revela la conducta de cada estrategia: PPO 100k mantiene 10% BTC, 65% S&P, 18% Bonos y 7% Cash, replicando una aproximación diversificada y conservadora. PPO 30k y especialmente PPO-T 30k incrementan drásticamente la exposición a BTC (hasta 90% en el Transformer), concentrando riesgo en el activo más volátil. El LSTM, por su parte, se resguarda con 60% Cash y apenas 5% BTC, lo que explica por qué su rendimiento queda relegado: evita drawdowns, pero renuncia a buena parte de la oportunidad alcista.



Figure 5. Rendimiento de Portafolio PPO vs S&P 500

En la curva de retorno acumulado, el agente PPO entrenado 100 k pasos (línea roja) parte inicialmente bajo el desempeño del “buy & hold” del S&P500 (línea punteada), pero a partir del tramo de validación (2017–2018) comienza a replicar y posteriormente a superar sistemáticamente el benchmark. Durante 2019–2024 el agente PPO añade aproximadamente un 10–15% extra de ganancia sobre la simple tenencia del índice, lo cual sugiere que la política aprendida logra capturar parte del momentum alcista del mercado y esquivar las caídas más profundas (p. ej. marzo 2020). En el segundo panel, donde ambas curvas se inician en cero para comparar desempeño relativo puro, se confirma que PPO 100k mantiene una ventaja consistente a lo largo del



Figure 6. Rendimiento Test PPO vs S&P 500

periodo test: logra acumulados de 140% frente al 130% del S&P al cierre de 2024, con una menor varianza. Además, durante los retrocesos (por ejemplo, finales de 2021) el PPO sufre repuntes más rápidos tras el mínimo, lo que sugiere un mecanismo de reequilibrio que le permite remontar ligeramente antes que el índice pasivo.




Figure 7. Perfil Riesgo–Retorno PPO vs S&P 500

En el scatter volatilidad vs retorno anual, el punto correspondiente a PPO 100k (retorno 15.7%, volatilidad 14.6%) se sitúa estratégicamente por encima de la línea de 45 grados, superando significativamente al S&P 500 (retorno 15.9%, volatilidad 20.2%). Este posicionamiento revela el valor práctico de PPO 100k: logra esencialmente el mismo retorno que el benchmark más popular, pero con una reducción sustancial del 37% en volatilidad. Para inversores que tradicionalmente optan por buy-and-hold del S&P 500, PPO 100k representa una alternativa superior que mantiene el rendimiento esperado mientras reduce significativamente la incertidumbre y el estrés asociado con las fluctuaciones del mercado.

En la gráfica de barras de métricas vemos que PPO 100k alcanza un retorno anual medio de aproximadamente 15.8%, un Sharpe ratio de aproximadamente 1.08 (multiplicado por 10 en la barra roja) y un drawdown máximo de aproximadamente 22.3%. Comparativamente, el buy & hold del S&P presenta 16.5% de retorno, Sharpe = 1.00 y drawdown = 18.4%. Aunque el S&P genera un pelín más de retorno bruto, el PPO reduce el riesgo de caídas medias y mejora la estabilidad (Sharpe superior), lo que podría resultar atractivo




Figure 8. Métricas PPO

para gestores que valoren la consistencia.

En resumen, estos resultados apuntan a un claro trade-off entre agresividad y estabilidad. Bitcoin Only domina en retornos absolutos (2365.8%) pero actúa como una "droga" para los modelos: aunque maximiza ganancias, su extrema volatilidad (65.8%) no representa una estrategia realista y sostenible de trading. Entre los modelos ML, PPO-T 30k potencia retornos explosivos (36.1% anual) pero con drawdowns severos (-76.2%).

****Descubrimiento clave**:** PPO 100k logra un hallazgo notable al replicar el retorno del S&P 500 (15.7% vs 15.9% anual) pero con volatilidad significativamente menor (14.6% vs 20.2%). Este resultado es especialmente valioso considerando que el buy-and-hold del S&P 500 representa la estrategia de inversión más común. PPO 100k no solo iguala el rendimiento del benchmark tradicional, sino que lo hace con 37% menos volatilidad y mejor Sharpe ratio (1.08 vs 0.79), ofreciendo una alternativa más estable para inversores que buscan consistencia.

Para futuras iteraciones se sugiere incorporar regularización de riesgo en la recompensa, backtests en otros períodos extremos y ajustar costos de transacción dinámicos, con el fin de afinar aún más el equilibrio riesgo-retorno. Además, se propone la creación de políticas que le permitan a los modelos identificar mejor las tendencias alcistas y bajistas, buscando motivar a que se muevan a carteras más conservadoras en períodos de tendencias bajistas o a carteras más riesgosas en períodos de tendencias alcistas.

6. Conclusión

Se presentó una comparación de enfoques de aprendizaje por refuerzo y supervisado aplicados al trading en un portafolio multi-activo. Los experimentos se diseñaron con

costos de transacción realistas y métricas financieras relevantes. Los resultados muestran que PPO 100k optimiza mejor el retorno ajustado al riesgo (Sharpe 1.08) que el modelo LSTM (Sharpe 0.91), mientras que PPO-T 30k prioriza retornos absolutos a costa de mayor volatilidad. El hallazgo más significativo es que PPO 100k replica el retorno del S&P 500 (15.7% vs 15.9% anual) con 37% menos volatilidad, proporcionando una alternativa más estable a la estrategia de inversión más popular. Bitcoin Only establece el benchmark de máximo retorno, pero su extrema volatilidad lo convierte en una opción poco realista para trading sostenible. Se reconoce la necesidad de análisis adicionales, tales como la incorporación de más activos, el uso de funciones de recompensa alternativas y la exploración de estrategias híbridas que integren predicciones supervisadas con optimización por refuerzo.

Código y reproducibilidad: Todos los experimentos, modelos entrenados y código fuente están disponibles públicamente en: <https://github.com/sebaterrazas/Trading-PPO-LSTM-Comparison> para garantizar la reproducibilidad completa de los resultados.

References

- Fischer, T. and Krauss, C. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2):654–669, 2018. doi: 10.1016/j.ejor.2017.11.054.
- Hochreiter, S. and Schmidhuber, J. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. URL <https://arxiv.org/abs/1707.06347>.
- Sutton, R. S. and Barto, A. G. *Reinforcement Learning: An Introduction*. MIT Press, 2018.